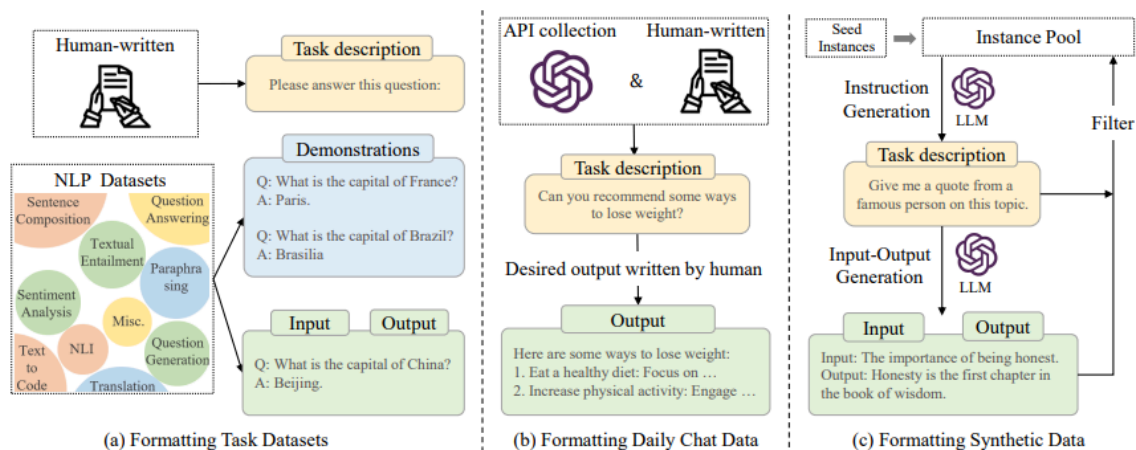


Relatório 7 - Leitura: Adaptação LLM (II)

Vitor Eduardo de Lima Kenor

Descrição da atividade

Neste card vamos fazer a leitura do tópico 5 do artigo “A Survey of Large Language Models”. Este tópico começa abordando como o pós-treinamento de LLMs permite adaptar modelos pré-treinados para tarefas específicas. As duas principais abordagens discutidas no artigo são instruction tuning e alignment tuning. No instruction tuning, o modelo é ajustado com exemplos em linguagem natural, incluindo descrição da tarefa, entrada, saída e demonstrações. No artigo é dito que essa técnica tem sido amplamente utilizada em modelos como InstructGPT e GPT-4.



Esta imagem foi retirada do artigo, e nela temos três métodos diferentes para construir as instâncias formatadas para o instruction tuning de LLMs. Mais para o meio do tópico 5, são apresentadas estratégias para formatar os dados de instrução a fim de melhorar o instruction tuning. Uma estratégia citada foi a do InstructGPT que utilizou consultas reais enviadas à API da OpenAI para criar instruções mais alinhadas às necessidades humanas, outra é a do GPT-4 que introduziu instruções de alto risco para treinar o modelo a rejeitá-las por segurança. É explicado que a construção de dados de instrução eficazes depende da escala das tarefas, do design adequado das instruções, da qualidade dos dados e da seleção criteriosa de exemplos. No instruction tuning, equilibrar datasets variados e utilizar dados de alta qualidade melhora o desempenho do modelo. Estratégias práticas incluem um treinamento com conversas inteiras em vez de pares isolados para economizar recursos e definir identidade do modelo com instruções específicas. O artigo mostra que o instruction tuning melhora o desempenho de LLMs de diversos tamanhos e arquiteturas, permitindo a generalização para tarefas novas e diferentes idiomas. Além disso, permite especialização em domínios como medicina e direito, um exemplo disso é o modelo Med-PaLM que foi citado no artigo.

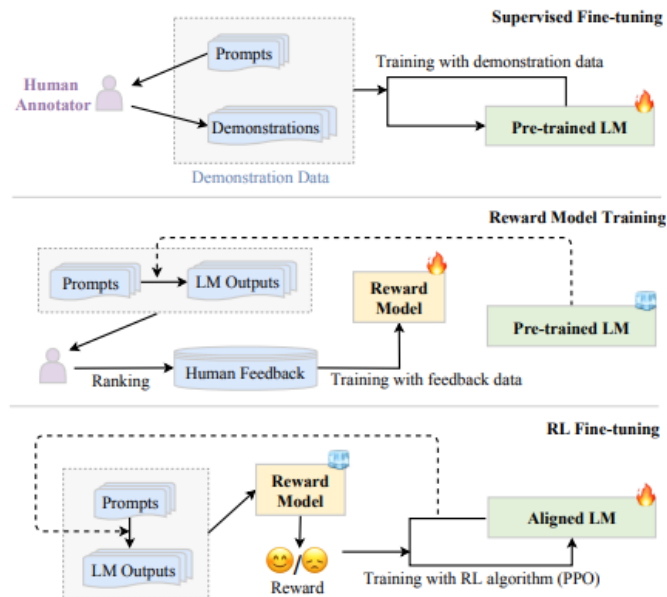


Fig. 12: The workflow of the RLHF algorithm.

Esta outra imagem retirada do artigo ilustra o fluxo de trabalho do algoritmo (RLHF) Reinforcement Learning from Human Feedback, dividido em três etapas: A primeira o modelo pré-treinado é ajustado com dados de demonstração fornecidos por humanos, que incluem exemplos de prompts e respostas desejadas; A segunda o modelo gera respostas para os prompts, que são avaliadas e ranqueadas por humanos. Essas avaliações são usadas para treinar um modelo de recompensa que aprende a distinguir respostas melhores; A terceira o modelo alinhado é ajustado usando um algoritmo de aprendizado por reforço, onde o modelo de recompensa orienta a otimização das respostas com base no feedback humano. Este trecho do tópico 5 demonstra como os LLMs podem ser alinhados com valores humanos para melhorar a utilidade, honestidade e segurança. No final do tópico 5, é abordado que o valor do ajuste de LLMs é alto por causa do grande número de parâmetros, e o artigo traz métodos eficientes que foram desenvolvidos para reduzir os parâmetros treináveis sem comprometer muito o desempenho. Os métodos são: Adapter Tuning: Pequenos módulos adapters são adicionados às camadas do transformer e treinados separadamente, mantendo os parâmetros do modelo principal congelados; Prefix Tuning: Insere vetores treináveis como prefixos nas camadas do transformer, permitindo ajuste específico sem modificar o modelo base; Prompt Tuning: Adiciona vetores treináveis diretamente na entrada do modelo, funcionando como um prompt suave para especialização em tarefas; LoRA (Low-Rank Adaptation): Utiliza decomposição de matrizes para representar as atualizações dos parâmetros de forma eficiente, reduzindo consumo de memória e VRAM; No entanto, ainda há poucas pesquisas sobre o impacto desses métodos em LLMs de grande escala.

Conclusões

Este tópico analisado do artigo nos trouxe que o pós-treinamento dos LLMs é fundamental para torná-los mais úteis e alinhados às necessidades humanas. Técnicas como instruction tuning e alignment tuning ajudam os modelos a entender melhor as tarefas e gerar

respostas mais seguras e precisas. Com esses avanços, os LLMs poderão ser cada vez mais úteis em diversas áreas, como atendimento ao cliente, medicina, direito e etc.

Referências

Link do artigo "A Survey of Large Language Models":

<https://arxiv.org/pdf/2303.18223>